



Proyecto 2: Resultados Parciales y Visualizaciones Estáticas

Nancy Mazariegos 22513
Brandon Morales - 22992
Santiago Pereira - 22318
Andre Jo - 22199

Introducción

La predicción de precios de commodities es un desafío grande en el análisis de series de tiempo debido a la naturaleza no lineal, no estacionaria y estocástica de estos datos financieros. Los mercados de commodities están influenciados por múltiples factores como condiciones macroeconómicas, eventos geopolíticos, cambios climáticos y dinámicas de oferta y demanda, lo que genera alta volatilidad y patrones temporales complejos. A continuación se presenta la revisión bibliográfica de todos los posibles algoritmos o modelos de ML y DL que se pueden adaptar a las necesidades de este proyecto en particular.

Revisión bibliográfica

Algunos de los modelos más capacitados para la resolución de este problema en particular son los siguientes:

1. Redes Neuronales Recurrentes (RNN, LSTM, GRU)

Las redes neuronales recurrentes han demostrado ser efectivas para el pronóstico de series temporales financieras. Ben Ameur et al. (2023) aplicaron modelos RNN, GRU y LSTM para predecir índices de commodities, concluyendo que los modelos de deep learning tienen un rendimiento sólido en la predicción de precios de commodities, siendo LSTM el que mostró la capacidad predictiva más óptima.

2. Redes Neuronales Convolucionales (CNN)

Las CNN, aunque inicialmente diseñadas para aplicaciones de visión por computadora, han sido adaptadas exitosamente para problemas unidimensionales como series de tiempo. Boubaker et al. (2021) lograron predecir con éxito la irradiación horizontal global (GHI) diaria utilizando CNN.

3. Arquitecturas Transformer para Series de Tiempo

Los modelos Transformer han revolucionado el campo del procesamiento de lenguaje natural y recientemente han sido adaptados con éxito para el pronóstico de series temporales. Según un estudio reciente publicado en enero de 2025, el mecanismo de auto-atención del Transformer permite el aprendizaje adaptativo de dependencias a corto y largo plazo mediante interacciones de solicitud por pares (consulta-clave), otorgando al Transformer una ventaja significativa en el aprendizaje de dependencias a largo plazo en datos secuenciales como lo son los datos financieros.

4. XGBoost y LightGBM

Los algoritmos de gradient boosting han demostrado ser altamente efectivos para la predicción de series temporales financieras. Un estudio reciente de julio de 2025 evaluó el rendimiento de algoritmos de machine learning y deep learning para pronosticar precios de commodities agrícolas, mostrando que los modelos de deep

learning, particularmente Long Short-Term Memory y Gated Recurrent Units, superan a otros en la captura de patrones temporales complejos.

Selección de algoritmos

Con base en la revisión bibliográfica realizada y considerando las características específicas del problema de predicción de precios de commodities en el contexto de la competencia de Kaggle Mitsui Commodity Prediction Challenge, se propone implementar y comparar los siguientes algoritmos y arquitecturas:

- **SARIMA:** valida si la dinámica es mayormente lineal/estacional.
- **Ridge/Lasso:** identifica lags relevantes y controla sobreajuste.
- **XGBoost:** modela no linealidad e interacciones de lags/rollings con buen desempeño y costo bajo.
- **LSTM (piloto):** prueba de concepto para dependencias largas; si no mejora, se difiere el despliegue a la entrega final.

Datos

Variable objetivo y Horizonte: hpasos.

Partición temporal: 70% *train* – 15% *valid* – 15% *test*, sin barajar.

Preprocesamiento de datos:

- Diferenciación con SARIMA.
- Escalado sólo con *train* (para DL/Regresión).

Tuning (parcial):

- SARIMA: búsqueda corta en $(p,d,q) \times (P,D,Q)$, $D \in \{0,1\}$, $s \in \{7/12/\dots 7/12/\dots 7/12/\dots\}$, selección por AICc y error en validación.
- Ridge/Lasso: $\alpha \in \{0.01, 0.1, 1, 10\}$.
- XGBoost: $n_estimators \in \{300, 500\}$, $max_depth \in \{3, 5\}$, $learning_rate \in \{0.03, 0.1\}$, $subsample=0.8$.
- LSTM: ventana 30, 32 unidades, dropout 0.2, early stopping (≤ 50 epochs).

Evaluación y métricas:

- **Métricas:** MAE, RMSE, MAPE y R^2 en validación (promedio K cortes) y test.
- **Eficiencia:** tiempo de entrenamiento e inferencia (ms/paso) para SARIMA/XGB/LSTM.
- **Diagnóstico:** residuales vs tiempo y distribución (histograma o Q-Q).

Graficos:

Gráfico 1: ARIMA JPX Gold Mini Futures Closes Residuales (histograma)

ARIMA - JPX_Gold_Mini_Futures_Close - Residuales (histograma)




Gráfico 2: Real vs Predicho — Close (Standard)




Gráfico 3:Scatter $y=x$ — Close (Standard)




Gráfico 4 : Residuales en el tiempo — Close (Standard)




Gráfico 5:Serie: Real vs. Predicho – Close




Gráfico 6: Scatter: y_real vs. y_pred – Close




Gráfico 7: Serie: Real vs. Predicho – Mini Close




Gráfico 8: Scatter: y_real vs. y_pred – Mini Close




Gráfico 9: Serie: Real vs Predicho – Close GRU




Gráfico 10: Scatter: y_real vs y_pred mini close GRU




Gráfico 11: TFT Puro Pythorch JPX Gold Futures Low





Gráfico 12: TFT Puro Pythorch Settlement price



Resultados:

ARIMA (walk-forward, 1 paso)

- JPX_Gold_Standard_Futures_Close (ARIMA (2,1,2)):
 - MAE = 132.18
 - MSE = 68,646.97
 - RMSE = 262.01
- JPX_Gold_Standard_Futures_High (ARIMA (1,0,2)):
 - MAE = 113.64
 - MSE = 69,136.38
 - RMSE = 262.94
- Patrones visuales:
 - Real vs Predicho: superposición alta tras el arranque.
 - Scatter: puntos cercanos a la diagonal $y=xy=xy=x$.
 - Residuales: gran outlier negativo en el primer(s) paso(s); luego, ruido alrededor de 0.

Regresión Lineal (baseline)

- Variables analizadas:
 - JPX_Gold_Mini_Futures {Open, Close, Settlement_price}
 - JPX_Gold_Standard_Futures {Open, Close, High, Low}.

Métrica	Valor	Interpretación
MAE	~6,500–7,000	Extremadamente alto
Sesgo	–6,500 a –7,000	Subestimación constante

R^2	≈ 0	Sin poder predictivo
Rango Residuales	-7,400 a -6,100	Estrecho y negativo

- Reales: 15,000–16,500; Predichos: 8,500–9,500 → brecha ~43%.
- Scatter lejos de la diagonal; línea temporal con banda naranja muy por debajo.

LSTM (Long Short-Term Memory)

- JPX_Gold_Mini_Futures y JPX_Gold_Standard_Futures (Open/High/Low/Close/Settlement).

Métrica	Valor	Interpretación
MAE	~8,500–9,000	Peor que regresión
Sesgo	-8,500 a -9,000	Subestimación severa
R^2	< 0	Peor que promedio
Rango Residuales	-9,400 a -7,800	Muy concentrado
Varianza de $\hat{y}$	≈ 0	Predicción casi constante

- Predice ~7,000 casi plano para todas las observaciones.
- Scatter con línea horizontal; serie temporal naranja plana.
- Patrón idéntico en todas las variables → fallo sistemático.

Modelo GRU:

Resultados Cuantitativos

Target	MAE	RMSE
JPX_Gold_Standard_Futures_Low	74.98	9,280.39
JPX_Gold_Mini_Futures_Close	86.69	13,561.65
JPX_Gold_Mini_Futures_settlement_price	87.96	14,641.70

JPX_Gold_Mini_Futures_Low	96.72	14,481.10
JPX_Gold_Mini_Futures_High	105.85	15,477.97
JPX_Gold_Standard_Futures_Close	109.23	20,148.47
JPX_Gold_Mini_Futures_Open	128.51	21,793.33
JPX_Gold_Standard_Futures_Open	130.39	25,391.21
JPX_Gold_Standard_Futures_High	177.40	44,789.86

Comparaciones:

Comparación con ARIMA

Target	ARIMA MAE	GRU MAE	Mejora
JPX_Gold_Standard_Futures_Close	132.18	109.23	17.3%
JPX_Gold_Standard_Futures_High	113.64	177.40	-56.1%

Modelo TFT:

Resultados Cuantitativos

Target	MAE	RMSE
JPX_Gold_Standard_Futures_Low	79.4265	13935.6875
JPX_Gold_Mini_Futures_Close	153.7720	34428.9609
JPX_Gold_Mini_Futures_settlement_price	151.4007	32318.1855
JPX_Gold_Mini_Futures_Low	109.6639	18210.0117
JPX_Gold_Mini_Futures_High	121.5429	20811.8398
JPX_Gold_Standard_Futures_Close	114.4516	22151.4707
JPX_Gold_Mini_Futures_Open	164.6492	34950.30
JPX_Gold_Standard_Futures_Open	446.3265	212725.64
JPX_Gold_Standard_Futures_High	80.5253	10657.3486

Comparaciones:

Comparación con ARIMA

Target	ARIMA MAE	TFT MAE	Mejora
--------	--------------	---------	--------

JPX_Gold_Standard_Futures_Close	132.18	114.4516	15.4%
JPX_Gold_Standard_Futures_High	113.64	80.5253	-41.1%

Discusión de resultados

Modelos ARIMA, LSTM y Regresión lineal

ARIMA demostró ser el modelo más confiable para predicción a corto plazo, capturando efectivamente las tendencias locales con residuales centrados tras el período inicial. Las métricas obtenidas son aceptables para nowcasting de 1 paso, aunque presenta un outlier inicial debido a la ventana corta en walk-forward que se estabiliza posteriormente. Por otro lado, tanto Regresión Lineal como LSTM presentaron fallos sistemáticos críticos con errores del 42-55% del precio real, predicciones consistentemente subestimadas y $R^2 \approx 0$, indicando problemas estructurales en normalización/desnormalización, posible desalineación temporal de datos, y falta de variables predictoras clave como indicadores macroeconómicos y de volatilidad.

Modelo GRU:

El modelo GRU demuestra capacidad superior para capturar patrones temporales complejos en la mayoría de targets, especialmente en JPX_Gold_Standard_Futures_Low e instrumentos Mini Futures que muestran errores consistentemente menores. Pero por otro lado este modelo demuestra rendimiento inferior en JPX_Gold_Standard_Futures_High comparado con ARIMA, indicando que algunos targets pueden beneficiarse más de enfoques estadísticos tradicionales.

Modelo TFT:

El modelo TFT (Temporal Fusion Transformer) logra capturar adecuadamente la tendencia general del precio del oro, mostrando una buena alineación en la dirección de los movimientos y el nivel promedio. Sin embargo, la curva predicha aparece mucho más suavizada que la real, lo que indica que el modelo subestima la volatilidad y no logra reflejar con precisión los picos y caídas abruptas del mercado. Esto es común en los TFT cuando se visualiza únicamente la mediana (cuantil 0.5), ya que el modelo tiende a priorizar la estabilidad sobre la variabilidad. En general, los resultados sugieren un desempeño sólido para proyecciones de tendencia y comportamiento a mediano plazo, pero con limitaciones para capturar fluctuaciones de corto plazo o movimientos extremos, por lo que podría beneficiarse de ajustar la regularización, incorporar más variables explicativas o considerar intervalos de predicción para representar mejor la incertidumbre del mercado.

Conclusiones

El análisis comparativo de los modelos implementados evidencia que no existe un único enfoque óptimo para la predicción de precios de commodities. En términos generales, el modelo ARIMA se posiciona como un modelo base sólido para pronósticos de corto plazo, especialmente cuando las series presentan patrones locales estables. Su capacidad para capturar tendencias inmediatas lo hace útil como referencia o punto de partida en escenarios de nowcasting.

Por otro lado, los resultados obtenidos con LSTM y Regresión Lineal mostraron limitaciones importantes, reflejando subestimación sistemática y baja capacidad de generalización. Esto sugiere la necesidad de revisar el preprocesamiento y enriquecer el conjunto de variables con factores externos —como indicadores la volatilidad y entre otros aspectos que aporten contexto al comportamiento del mercado.

El modelo GRU demostró un desempeño más equilibrado, con mejoras notables respecto a ARIMA en ciertos instrumentos, lo que confirma su capacidad para modelar dependencias no lineales y patrones secuenciales complejos. Sin embargo, su rendimiento no fue consistente en todas las variables, indicando que la arquitectura puede requerir ajustes en hiperparámetros o mayor regularización.

Finalmente, el TFT (Temporal Fusion Transformer) se destacó por su habilidad para representar tendencias globales y capturar relaciones entre variables estáticas y dinámicas, mostrando un comportamiento suave y estable. No obstante, su tendencia a suavizar las predicciones redujo la sensibilidad ante movimientos bruscos o picos de volatilidad, un aspecto crítico en mercados financieros. Esto sugiere que el modelo podría fortalecerse mediante la calibración de cuantiles, la incorporación de variables exógenas y el ajuste de la función de pérdida para reflejar mejor la incertidumbre inherente al mercado.

Bibliografía:

- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2016). *Time Series Analysis: Forecasting and Control* (5th ed.). Wiley. — Marco ARIMA/SARIMA, criterios AICc y diagnósticos ACF/PACF.
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.). OTexts. — Baselines (Naive/S-Naive), ETS y *time-series cross-validation* evitando fuga.
- Hochreiter, S., & Schmidhuber, J. (1997). LSTM. *Neural Computation*, 9(8), 1735–1780. — Dependencias largas/no lineales.

- Lim, B., & Zohren, S. (2021). Time series forecasting with Transformer-based models. *arXiv:2001.08317*. — Atención e interpretabilidad para series multivariadas.
- Oreshkin, B. N., et al. (2020). N-BEATS. *ICLR*. — DL competitivo sin *feature engineering* pesado.
- Chen, T., & Guestrin, C. (2016). XGBoost. *KDD*. — No linealidad, interacciones y SHAP.

Codigos:

Modelos ARIMA, Regresion Lineal, LSTM

<https://colab.research.google.com/drive/15KnITv-sM36RI5ZDuYe6M4Ek7it9LBPZ?usp=sharing>

Modelos: Gru,tft

<https://colab.research.google.com/drive/1xrcb6RIjxh7LUslFAEcf94YQXLYYEgDr?usp=sharing>